

교과목 3 : 초거대언어모델(LLM)

단원 5 : 파인 튜닝

DAY1. LLM 파인 튜닝 기법과 sLLM_모델 이해

목 차

1. 파인 튜닝 개념과 튜닝 기법		3
2. sLLM의 개념과 기술		16
3. Huggingface & Transformer		31
4. RunPod기반 LLM 파인튜닝 실습		21

1. 파인 튜닝 개념과 LLM 파인 튜닝 기법

1. 파인 튜닝(Fine-tuning)이란?

파인 튜닝(Fine-tuning)은 이미 학습이 완료된 사전학습(Pre-trained) 모델을 특정 목적에 맞게 추가 학습시키는 과정이다.

대규모 언어모델(LLM)은 인터넷의 방대한 데이터를 이용하여 일반적인 언어 능력을 학습한다.

하지만 실제 업무에서는


- 회사 내부 문서
- 의료
- 법률
- 금융
- 제조
- 고객센터

등 특정 분야의 전문 지식을 필요로 한다.

이러한 분야는 일반적인 GPT 학습만으로는 충분하지 않다. 따라서 기존 모델의 지식을 유지하면서 특정 분야의 능력을 향상시키는 방법이 바로 **Fine-tuning** 이다.


즉, 기존의 언어 능력은 유지하면서 새로운 업무를 배우는 과정이라고 이해하면 된다.

2. Pre-tuning 과 Fine-tuning 의 차이



Pre-training 은 새로운 언어모델을 만드는 과정이다. Fine-tuning 은 이미 만들어진 모델을 업무에 맞게 수정하는 과정이다.

3. LLM 학습 과정



최근 LLM 은 대부분 위 순서로 발전한다.

4. 파인 튜닝(Fine-tuning)하는 이유

대표적인 목적은 다음과 같다.

(1) 도메인 지식 추가

예


- 의료

- 법률
- 보험
- 특허
- 회계

GPT 는 일반적인 의학은 알지만 병원 내부 규정은 모른다. 따라서 내부 데이터를 학습시킨다.

(2) 답변 스타일 변경

예




(3) 특정 업무 수행

예

- 상품 추천
- 계약서 분석
- 코드 생성
- SQL 생성
- 보고서 작성
- 문서 분류


(4) 성능 향상

같은 질문이라도




5. 파인 튜닝(Fine-tuning) 종류

LLM에서는 크게 다음과 같이 구분한다.



1. Full Fine-tuning

가장 기본적인 방법이다. 모든 파라미터를 업데이트한다.



장점

- 가장 높은 성능
- 모든 업무 가능
- 자유도가 높음

단점


- GPU 많이 필요
- 학습 시간이 길다
- 비용이 크다

예

70B 모델 : GPU 8~32 개 이상

2. Transfer Learning


Transfer Learning 은 기존 모델의 지식을 새로운 문제에 활용하는 기술이다.



Fine-tuning 자체가 Transfer Learning 의 대표적인 사례이다.

3. Feature Extraction

Transformer 는 그대로 두고 출력만 학습한다.



예

감정 분석 :


- 긍정
- 부정
- 중립

4. Instruction Tuning

최근 LLM 에서 가장 많이 사용되는 방법이다.


질문과 답변 데이터를 이용하여 모델이 사람의 지시를 따르도록 학습한다.

예



5. Supervised Fine-Tuning(SFT)

Instruction Tuning 의 핵심 방법이다. 사람이 만든 정답을 학습한다.



예

질문 :

"파이썬 리스트를 설명해"

↓


정답 :

"리스트는 순서가 있는 자료구조입니다."

6. RLHF (Reinforcement Learning from Human Feedback)

최근 GPT 계열에서 중요한 기술이다.

과정



사람이 :

답변 A

답변 B

↓

더 좋은 답변 선택


이를 보상 모델이 학습한다.

7. PEFT(Parameter Efficient Fine-Tuning)

최근 가장 많이 사용하는 방법이다.

전체 모델을 수정하지 않는다.

일부 파라미터만 수정한다.




장점

- GPU 적음
- 빠름
- 비용 저렴

8. Adapter Tuning


각 Layer 사이에 작은 네트워크를 추가한다.



원래 모델은 수정하지 않는다.

9. LoRA (Low-Rank Adaptation)

현재 가장 많이 사용하는 Fine-tuning 기법이다. 기존 Weight 는 그대로 둔다.




수식 :

$$W' = W + \Delta W$$

$$\Delta W = A \times B$$

A 와 B 만 학습한다.

LoRA 동작 구조



실제로는


W : Frozen

BA : Train

만 수행된다.

10. QLoRA


LoRA 를 더 발전시킨 방법이다. 모델을 4bit 양자화한다.



장점


메모리가 매우 적게 사용된다.

예



11. Prompt Tuning


모델은 수정하지 않는다. Prompt Embedding 만 학습한다.



학습량이 매우 적다.

12. Prefix Tuning


각 Layer 앞에 Virtual Token 을 추가한다.



13. P-Tuning


Prompt Tuning 보다 발전된 방식이다.

Prompt 자체를 학습 가능한 벡터로 만든다.



14. IA3

Attention 내부의 Scale 값만 수정한다.



매우 적은 파라미터만 변경한다.

6. Fine-tuning 전체 비교

방법	학습 대상	GPU 요구량	성능	활용 사례
Full Fine-tuning	전체 파라미터	매우 높음	매우 높음	자체 LLM 개발, 연구
Feature Extraction	출력 계층	낮음	보통	분류, 감정 분석
Instruction Tuning(SFT)	모델(전체 또는 일부)	중간~높음	높음	대화형 LLM, QA
Adapter	추가 Adapter	낮음	높음	다중 태스크
LoRA	저랭크 행렬(A, B)	낮음	매우 높음	기업 맞춤 LLM
QLoRA	LoRA + 4bit 양자화	매우 낮음	높음	단일 GPU 환경
Prompt Tuning	프롬프트 임베딩	매우 낮음	보통	스타일 제어
Prefix Tuning	Prefix 벡터	매우 낮음	보통~높음	생성 작업
IA3	Attention 스케일	매우 낮음	높음	연구 및 경량화
RLHF	보상 모델 기반 정책	매우 높음	매우 높음	ChatGPT 수준 정렬(Alignment)

7. Fine-tuning 과 RAG의 차이

항목	Fine-tuning	RAG
목적	모델 내부 지식 변경	외부 지식 검색 후 활용
데이터 반영	학습을 통해 모델에 내재화	검색 시점에 최신 데이터 반영
최신성	재학습 필요	문서만 업데이트하면 즉시 반영
비용	학습 비용이 큼	구축 비용은 있으나 학습 비용은 낮음
환각(Hallucination)	감소 가능하지만 완전히 제거되지는 않음	검색 근거를 제시하여 환각 감소에 유리
적합한 사례	답변 스타일, 전문 용어, 특정 작업 습득	사내 문서 검색, 규정, FAQ, 최신 정보

실무에서는 둘 중 하나만 사용하는 경우보다 **RAG + LoRA/QLoRA 기반의 경량 파인 튜닝을 결합**하는 경우가 많다. 예를 들어, 모델은 LoRA 로 회사의 응답 스타일과 업무 절차를 학습하고, 실제 답변 시에는 RAG 로 최신 사내 문서와 정책을 검색하여 근거 기반 응답을 생성하는 구조가 널리 사용된다.

8 실무에서의 LLM 파인 튜닝 절차

- ① 데이터 수집
↓
- ② 데이터 정제 및 품질 검증
↓
- ③ 학습 데이터 구성 (Instruction / Input / Output)
↓
- ④ 토큰나이징 (Tokenization)
↓
- ⑤ 베이스 모델 선택 (Llama, Qwen, Mistral 등)
↓
- ⑥ 학습 기법 선택 (LoRA, QLoRA, Full Fine-tuning 등)

- ↓
- ⑦ 모델 학습
- ↓
- ⑧ 검증(Evaluation)
- 정확도
 - BLEU / ROUGE / BERTScore(생성 작업)
 - 작업별 벤치마크
- ↓
- ⑨ 추론 최적화 (양자화, vLLM, TensorRT-LLM 등)
- ↓
- ⑩ 배포 및 모니터링

9. 최신 실무 동향

최근 LLM 개발에서는 다음과 같은 방향이 주류이다.

- **SFT(Supervised Fine-Tuning)**로 기본적인 지시 수행 능력을 학습한다.
- **Preference Optimization**(예: DPO, ORPO 등)을 사용해 사람의 선호를 반영하며, RLHF의 일부 단계를 단순화하는 경우가 증가하고 있다.
- **LoRA/QLoRA**를 활용하여 GPU 자원을 절감하면서도 높은 성능을 확보한다.
- **RAG**를 결합하여 최신 정보와 내부 문서를 실시간으로 활용한다.
- **양자화(4-bit, 8-bit)**와 고성능 추론 엔진을 적용하여 서비스 비용과 응답 속도를 최적화한다.

핵심 정리

- **Pre-training**은 범용 언어 능력을 학습하는 단계이다.
- **Fine-tuning**은 특정 도메인이나 업무에 맞게 모델을 추가 학습시키는 과정이다.
- **SFT**는 정답 데이터를 이용해 지시 수행 능력을 향상시키는 대표적인 파인 튜닝 방식이다.
- **PEFT**는 적은 수의 파라미터만 학습하여 효율성을 높이는 기법군이며, **LoRA**와 **QLoRA**가 가장 널리 활용된다.
- **RLHF** 및 최신 **Preference Optimization** 기법은 모델의 응답을 사람의 선호와 안전성에 맞게 정렬하는 데 사용된다.
- 실무에서는 **RAG**와 경량 파인 튜닝(**LoRA/QLoRA**)을 결합하여 최신 정보 활용, 비용 절감, 응답 품질 향상을 동시에 달성하는 아키텍처가 가장 일반적이다.

2. sLLM(Small Language Model)의 개념과 기술

1. sLLM(Small Language Model)이란?

sLLM(Small Language Model)은 적은 수의 파라미터(Parameter)를 가지면서도 특정 목적에 최적화된 언어모델을 의미한다. 최근 AI 분야에서는 GPT-4, Claude, Gemini 와 같은 초거대 언어모델(Large Language Model, LLM)이 발전했지만, 모든 서비스에 수백억~수천억 개의 파라미터를 가진 모델이 필요한 것은 아니다.

실무에서는 다음과 같은 요구가 많다.

- 응답 속도가 빨라야 한다.
- GPU 비용을 줄여야 한다.
- 모바일이나 PC 에서도 실행되어야 한다.
- 개인정보가 외부로 나가지 않아야 한다.
- 특정 업무만 잘 수행하면 된다.

이러한 요구를 만족하기 위해 등장한 것이 sLLM 이다.


즉, sLLM 은 특정 목적에 맞게 경량화되고 최적화된 언어모델이다.

2. sLLM(Small Language Model)과 LLM 비교

구분	LLM	sLLM
모델 크기	매우 큼	작음
파라미터	수십억~수천억	수억~수십억
GPU 요구량	높음	낮음
응답속도	상대적으로 느림	빠름
비용	높음	낮음
모바일 실행	어려움	가능
Edge Device	제한적	가능
Fine-tuning	비용 큼	비용 적음
추론속도	느림	빠름

3. 왜 sLLM(Small Language Model)이 필요한가?

초거대 모델은 성능이 뛰어나지만 다음과 같은 문제가 있다.



예를 들어

- 고객센터 FAQ
- 상품검색
- 문서요약
- 분류
- 번역

등의 업무는 70B 모델까지 필요하지 않은 경우가 많다.


따라서

- 7B
- 3B
- 1B
- 500M

정도의 모델만으로도 충분한 경우가 많다.

4. sLLM(Small Language Model)의 등장 배경

AI 산업은 다음과 같이 변화하고 있다.




즉, "더 큰 모델" 에서 "더 효율적인 모델"로 패러다임이 바뀌고 있다.

5. sLLM(Small Language Model) 특징

(1) 빠른 추론

예를 들어



실시간 서비스에 매우 유리하다.

(2) 작은 메모리

예

모델	메모리
GPT 급	수백 GB
70B	140GB 이상
7B	약 14GB(FP16 기준)
3B	약 6GB
1B	약 2GB

양자화(INT8, INT4 등)를 적용하면 더 줄일 수 있다.

(3) Edge AI 가능

다음과 같은 환경에서 실행 가능하다.

- 스마트폰
- 자동차
- 로봇
- 공장
- 키오스크
- POS
- CCTV
- 의료장비

(4) 개인정보 보호

클라우드를 사용하지 않고 사내 PC에서 실행 가능하다.



6. sLLM(Small Language Model)의 핵심 기술

sLLM 은 단순히 작은 모델이 아니라, 다양한 최적화 기술을 통해 성능을 유지한다.

sLLM

- └── Distillation
- └── Quantization
- └── Pruning
- └── PEFT
- └── LoRA
- └── QLoRA
- └── MoE
- └── Flash Attention
- └── KV Cache
- └── Speculative Decoding

1. Model Distillation(지식 종류)

가장 중요한 기술이다. 큰 모델의 지식을 작은 모델에게 전달한다.

```
graph TD
    Teacher[Teacher : GPT] --> Student[학생 모델]
    Student --> SmallGPT[Small GPT]
```


학생 모델은 교사 모델의 출력 확률 분포(Soft Targets)까지 학습하여 일반화 성능을 높인다.

Distillation 과정

```
graph TD
    LargeModel[Large Model] --> AnswerGen[답변 생성]
    AnswerGen --> SoftLabel[Soft Label]
    SoftLabel --> SmallModel[Small Model 학습]
```

2. Quantization(양자화)

실수(FP32, FP16) 대신 정수(INT8, INT4 등)를 사용한다.




장점

- 메모리 감소
- GPU 감소
- 속도 증가

최근에는 GPTQ, AWQ, GGUF, bitsandbytes, FP8 등의 기법도 많이 활용된다.

3. Pruning

필요 없는 뉴런을 제거한다.




종류

- Weight Pruning
- Neuron Pruning
- Structured Pruning
- Unstructured Pruning


4. LoRA

작은 Adapter 만 학습한다.



5. QLoRA


LoRA + 4bit Quantization



현재 가장 많이 사용하는 방법이다.

6. Flash Attention

Transformer 의 Attention 을 최적화한다.




장점

- GPU 메모리 감소
- 계산량 감소
- 긴 문장 처리 개선

7. KV Cache

Transformer 는 이전 Token 을 다시 계산한다.

KV Cache 는 이미 계산한 결과를 저장한다.




결과

응답속도가 크게 향상된다.

8. Speculative Decoding


큰 모델 대신 작은 모델이 먼저 예측한다.



속도가 크게 향상된다.

9. Mixture of Experts(MoE)

MoE 는 모델 전체를 사용하는 대신 일부 전문가(Expert)만 활성화한다.




예를 들어 64 개의 Expert 가 있더라도 한 번의 추론에서는 2~8 개의 Expert 만 사용하여 연산량을 줄인다.

1. sLLM(Small Language Model)에서 사용하는 대표 모델

모델	파라미터(대략)	특징
Microsoft Phi-3 Mini	3.8B	작은 크기 대비 높은 추론 성능
Microsoft Phi-4 Mini	약 4B	코드·추론 성능 강화
Google Gemma 2B / 7B	2B / 7B	Google 공개 모델
Qwen2.5 3B / 7B	3B / 7B	다국어 및 코드 성능 우수
Llama 3.2 1B / 3B	1B / 3B	Edge 환경에 적합
SmolLM	수억~수십억	초경량 모델 연구
TinyLlama	약 1.1B	Llama 계열 경량 모델

8. sLLM(Small Language Model) 학습 과정



9 sLLM(Small Language Model)의 활용 분야

고객센터

질문
↓
FAQ
↓
답변

의료

증상
↓
병원 규정
↓
안내


제조

장비 오류
↓
매뉴얼 검색
↓
조치


금융

상품 질문
↓
상품 설명
↓
추천

모바일 AI




로봇




10. sLLM(Small Language Model) + RAG

최근 가장 많이 사용하는 구조이다.



모델 자체는 작지만, RAG 를 사용하면 큰 모델 수준의 업무도 상당 부분 수행할 수 있다.


11. sLLM(Small Language Model) + Agent



작은 모델도 Agent 구조와 도구(Tool)를 활용하면 복잡한 업무를 수행할 수 있다.

12. sLLM(Small Language Model) + MCP

최근에는 MCP(Model Context Protocol)와 함께 많이 사용된다.




Database
Slack
Browser
File
Calendar
Email


이 구조에서는 sLLM 이 모든 정보를 기억할 필요 없이 필요한 외부 시스템과 연결하여 작업을 수행한다.

13. sLLM과 LLM의 기술적 차이

항목	LLM	sLLM
목표	범용 지능	특정 업무 최적화
학습 데이터	인터넷 규모	인터넷 + 도메인 데이터
추론 비용	높음	낮음
배포 환경	클라우드 중심	클라우드 + 온프레미스 + Edge
최적화	선택적	필수(양자화, 증류, 캐시 등)
응답 속도	상대적으로 느림	매우 빠름
운영 비용	높음	낮음

14. 실무에서의 sLLM(Small Language Model) 구축 절차





15. 최신 기술 동향

현재 sLLM 연구와 산업 적용은 다음과 같은 방향으로 발전하고 있다.

- **고품질 데이터 기반 학습:** 모델 크기보다 데이터 품질과 학습 전략이 성능에 더 큰 영향을 미친다.
- **경량 파인 튜닝(PEFT):** LoRA, QLoRA, DoRA 등의 기법으로 적은 자원으로 도메인 적응을 수행한다.
- **추론 최적화:** KV Cache, FlashAttention, Speculative Decoding, 양자화를 조합하여 지연 시간을 최소화한다.
- **온디바이스 AI:** 스마트폰, PC, 차량, 산업용 장비에서 오프라인으로 실행되는 AI 가 확대되고 있다.
- **Agent + RAG + MCP 결합:** sLLM 이 외부 도구와 지식베이스를 활용하여 자체 파라미터 이상의 문제 해결 능력을 갖도록 하는 아키텍처가 확산되고 있다.

핵심 정리

- sLLM(Small Language Model)은 단순히 작은 모델이 아니라, 특정 목적에 맞게 최적화된 경량 언어모델이다.
- 핵심 기술은 지식 증류(Distillation), 양자화(Quantization), 가지치기(Pruning), PEFT(LoRA·QLoRA), 추론 최적화(KV Cache, FlashAttention)이다.
- RAG, Agent, MCP 와 결합하면 작은 모델도 외부 지식과 도구를 활용하여 높은 수준의 업무를 수행할 수 있다.
- 실무에서는 도메인 특화 업무, 개인정보 보호, 저비용 운영, 빠른 응답이 필요한 환경에서 sLLM 이 매우 효과적이다.
- 최근 AI 시스템은 "더 큰 모델"을 사용하는 것보다 "업무에 맞는 적절한 크기의 모델을 효율적으로 운영하는 것"을 목표로 설계되는 경우가 점점 늘어나고 있다.

3. Huggingface / Huggingface Transformer

1. Hugging Face 란?

Hugging Face는 AI 모델과 데이터셋을 공유하고 활용할 수 있는 대표적인 오픈소스 AI 플랫폼입니다.

주요 기능은 다음과 같습니다.

- Model Hub: Llama, Qwen, Gemma, BERT 같은 사전 학습 모델을 검색하고 다운로드할 수 있습니다.
- Dataset Hub: 자연어 처리, 이미지, 음성 등 다양한 학습용 데이터셋을 제공합니다.
- Transformers 라이브러리: 공개 모델을 Python 코드로 쉽게 불러와 추론하거나 파인 튜닝할 수 있습니다.
- Spaces: Gradio나 Streamlit으로 만든 AI 앱을 웹에서 실행하고 공유할 수 있습니다.
- 모델 저장소: 직접 파인 튜닝한 모델과 LoRA Adapter를 업로드해 보관할 수 있습니다.


예를 들어 다음과 같이 모델을 불러올 수 있습니다.

```
from transformers import AutoTokenizer, AutoModelForCausalLM

model_id = "Qwen/Qwen2.5-1.5B-Instruct"

tokenizer = AutoTokenizer.from_pretrained(model_id)
model = AutoModelForCausalLM.from_pretrained(model_id)
```

RunPod에서는 Hugging Face의 모델 ID와 데이터셋 ID를 지정해 Axolotl 기반 파인 튜닝을 진행할 수 있습니다.



즉, Hugging Face는 쉽게 말해 AI 모델과 데이터셋을 위한 GitHub와 같은 플랫폼이라고 이해할 수 있습니다.

2. Hugging Face Transformer 란?

Hugging Face Transformers는 사전 학습된 AI 모델을 Python에서 쉽게 불러와 사용하도록 지원하는 오픈소스 라이브러리입니다.

주로 다음 작업에 사용됩니다.

- 텍스트 생성
- 문장 분류
- 번역
- 요약
- 질의응답
- 감성 분석
- 이미지·음성 모델 활용
- 모델 파인 튜닝

대표적으로 BERT, GPT 계열, Llama, Qwen, Gemma, T5 등의 모델을 사용할 수 있습니다.

예를 들어 감성 분석 모델을 간단히 실행할 수 있습니다.

```
from transformers import pipeline

classifier = pipeline("sentiment-analysis")
result = classifier("This movie is very interesting.")
print(result)

# 모델과 Tokenizer를 직접 불러오는 방법은 다음과 같습니다.
from transformers import AutoTokenizer, AutoModelForCausalLM

model_id = "Qwen/Qwen2.5-1.5B-Instruct"
tokenizer = AutoTokenizer.from_pretrained(model_id)
model = AutoModelForCausalLM.from_pretrained(model_id)
```


여기서:

- AutoTokenizer는 문장을 모델이 이해할 수 있는 Token으로 변환합니다.
- AutoModelForCausalLM은 다음 Token을 예측하여 문장을 생성하는 모델을 불러옵니다.
- from_pretrained()는 Hugging Face Hub에서 사전 학습된 모델을 다운로드합니다.

즉, Hugging Face Transformers는 복잡한 딥러닝 모델을 적은 코드로 다운로드하고, 추론하고, 파인 튜닝할 수 있게 해주는 라이브러리입니다.

3. AI 개발 플랫폼 종류


RunPod와 같은 플랫폼은 클라우드 GPU를 임대하여 AI 모델을 학습(Fine-tuning)하거나 추론(Inference)할 수 있도록 제공하는 AI 개발 플랫폼입니다.

사용자는 고가의 GPU를 직접 구매하지 않고도 필요한 시간만 GPU를 사용할 수 있습니다.

대표적인 플랫폼은 다음과 같습니다.

플랫폼	특징	주요 용도
RunPod	저렴한 GPU 임대, Axolotl-vLLM 지원	LoRA/QLoRA 파인 튜닝, 추론
Google Colab	무료·유료 Notebook 환경	AI 실습, 교육, 간단한 모델 학습
Kaggle	무료 GPU와 데이터셋 제공	데이터 분석, 머신러닝 실습, 대회
Lambda Cloud	고성능 GPU 서버 제공	대규모 LLM 학습 및 연구
Vast.ai	GPU 마켓플레이스 방식	저렴한 GPU 임대, LLM 학습
Paperspace	Notebook과 GPU 서버 제공	AI 개발 및 딥러닝 실습
AWS SageMaker	AWS 기반 AI 플랫폼	기업용 AI 개발·학습·배포
Google Vertex AI	Google Cloud AI 플랫폼	기업용 AI 개발 및 MLOps
Microsoft Azure AI	Azure 기반 AI 서비스	AI 개발, 학습, 배포

플랫폼 구조



플랫폼별 특징

- RunPod: LoRA·QLoRA 파인 튜닝과 vLLM 배포에 최적화되어 있어 LLM 개발에 많이 사용됩니다.
- Google Colab: 별도 설치 없이 브라우저에서 Python과 GPU를 사용할 수 있어 교육과 실습에 적합합니다.
- Kaggle: 다양한 공개 데이터셋과 무료 GPU를 제공하여 머신러닝 학습과 대회 참가에 유용합니다.
- AWS SageMaker / Vertex AI / Azure AI: 기업 환경에서 AI 모델의 개발, 학습, 배포, 운영(MLOps)까지 통합 관리할 수 있는 서비스입니다.

4. RunPod 소개

RunPod는 클라우드에서 GPU 서버를 임대하여 **AI 모델의 학습(Fine-tuning)과 추론(Inference)**을 수행할 수 있는 **GPU 클라우드 플랫폼**입니다. 고가의 GPU를 직접 구매하지 않고도 필요한 시간 동안만 GPU를 사용할 수 있어 AI 개발자와 연구자, 교육기관에서 많이 활용됩니다.

주요 특징

- NVIDIA RTX 4090, A100, H100 등 다양한 GPU 제공
- 사용한 시간만큼 비용을 지불하는 종량제 방식
- Jupyter Notebook, Web Terminal, SSH 접속 지원
- Hugging Face 모델과 데이터셋 연동

- Axolotl 기반 LoRA-QLoRA 파인 튜닝 지원
- vLLM, Ollama, PyTorch, TensorFlow 등 다양한 AI 프레임워크 지원
- Docker 기반 개발 환경 제공


RunPod 사용 목적

RunPod는 다음과 같은 작업에 활용됩니다.

- LLM(대규모 언어 모델) 파인 튜닝
- LoRA-QLoRA 학습
- AI 모델 추론(API 서버 운영)
- Stable Diffusion 이미지 생성
- 딥러닝 연구 및 실습
- AI 애플리케이션 개발 및 테스트

RunPod 사용 절차

RunPod를 사용하는 기본 순서는 다음과 같습니다.



기본 사용 방법

1. 회원가입

- RunPod 홈페이지에서 계정을 생성합니다.
- 이메일 또는 Google, GitHub 계정으로 가입할 수 있습니다.

2. 결제 및 GPU 준비

- Billing 메뉴에서 결제 수단을 등록하거나 잔액을 충전합니다.
- 사용할 GPU(RTX 4090, A100 등)를 선택합니다.

3. Pod 생성

- 원하는 GPU와 스토리지를 선택하여 **Pod**를 생성합니다.
- Pod는 하나의 AI 개발 서버(가상 머신)라고 생각하면 됩니다.

4. 개발 환경 접속

Pod가 실행되면 다음과 같은 방법으로 접속할 수 있습니다.

- Jupyter Notebook
- Web Terminal
- SSH

5. AI 작업 수행

예를 들어 다음과 같은 작업을 수행할 수 있습니다.

- Hugging Face 모델 다운로드
- Axolotl로 LoRA 학습
- PyTorch 코드 실행
- vLLM으로 추론 서버 실행

6. 결과 저장


학습이 완료되면 결과를 다음과 같이 저장합니다.

- Hugging Face Hub 업로드
- 로컬 PC 다운로드
- Network Volume 저장

7. Pod 종료

작업이 끝나면 **Stop** 또는 **Terminate**를 선택하여 GPU 사용을 중지합니다.

RunPod 활용 예



RunPod의 장점

- 고성능 GPU를 직접 구매할 필요가 없습니다.
- 필요한 시간만 사용하여 비용을 절감할 수 있습니다.
- 다양한 AI 프레임워크를 즉시 사용할 수 있습니다.
- Hugging Face와 쉽게 연동하여 모델 학습과 배포가 가능합니다.
- 교육, 연구, 개인 프로젝트부터 기업용 AI 개발까지 폭넓게 활용할 수 있습니다.