

교과목 3 : 초거대언어모델(LLM)

단원 6 : 자연어-이미지 멀티모달

DAY2. GAN 기반 이미지 생성과 학습 방법

목 차

1. GAN 이란?		3
2. GAN 학습 알고리즘		12
3. TTS (Text to Speech)		17

1. GAN 이란?


GAN(Generative Adversarial Network)은 **생성자(Generator)**와 **판별자(Discriminator)**라는 두 개의 신경망이 서로 경쟁하면서 학습하여 실제와 매우 유사한 이미지를 생성하는 딥러닝 모델입니다.

2014 년 Ian Goodfellow 가 제안한 이후 이미지 생성 분야의 대표적인 기술로 사용되었습니다.

핵심 아이디어는 다음과 같습니다.

- 생성자(Generator)는 진짜 같은 이미지를 만들려고 합니다.
- 판별자(Discriminator)는 입력 이미지가 진짜인지 가짜인지 구분하려고 합니다.
- 두 모델이 서로 경쟁하면서 점점 성능이 향상됩니다.

이를 **적대적 학습(Adversarial Learning)**이라고 합니다.




[그림 1] GAN(Generative Adversarial Network)의 전형적인 학습 과정(Typical GAN Training Process)을 단계별로 나타낸 것입니다. 핵심은 **생성자(Generator)**와 **판별자(Discriminator)**가 서로 경쟁하며 반복적으로 학습하는 과정입니다.

[그림 1] 의 핵심 의미

이 그림은 GAN의 학습을 "생성 → 평가 → 개선 → 재생성"의 순환 구조로 표현한 것입니다.

- ① 랜덤 노이즈(z) 생성
- ▼
- ② Generator 가 가짜 이미지 생성
- ▼
- ③ Discriminator 가 진짜 이미지와 비교
- ▼
- ④ 진짜/가짜 여부를 판별하고 오차 계산
- ▼
- ⑤ Discriminator 의 가중치 업데이트
- ▼
- ⑥ Generator 가 판별 결과를 바탕으로 더 사실적인 이미지를 생성하도록 가중치 업데이트
- ▼
- ⑦ 새로운 이미지를 생성하여 다시 Discriminator 가 평가
- ▼
- ⑧ 이 과정을 반복하면서 생성 이미지의 품질이 점차 향상


결국 GAN 의 핵심은 **Generator** 는 판별자를 속이기 위해 더 사실적인 이미지를 생성하고, **Discriminator** 는 이를 구분하기 위해 더 정교하게 학습하는 적대적(Adversarial) 경쟁 구조에 있습니다. 이러한 경쟁이 반복될수록 두 모델의 성능이 함께 향상되며, 최종적으로는 실제와 매우 유사한 이미지를 생성할 수 있게 됩니다.



[그림 2]

[그림 2] 의 주요 구성 요소


- **Training Data:** 실제 이미지 데이터셋으로, 판별자가 진짜 이미지의 특징을 학습하는 데 사용됩니다.
- **Random Noise:** 생성자의 입력으로 사용되는 무작위 벡터입니다.
- **Generator(G):** 노이즈를 입력받아 실제와 유사한 가짜 이미지를 생성합니다.
- **Generated Fake Samples:** 생성자가 만든 가짜 이미지입니다.
- **Discriminator(D):** 실제 이미지와 가짜 이미지를 입력받아 진짜인지 가짜인지 판별합니다.
- **Discriminator Loss:** 판별자의 오차로, 진짜와 가짜를 얼마나 정확히 구분했는지를 나타냅니다.
- **Generator Loss:** 생성자의 오차로, 생성한 이미지를 판별자가 진짜로 인식하도록 만드는 정도를 나타냅니다.
- **Backpropagation:** 손실값을 이용해 역전파를 수행하고, 생성자와 판별자의 가중치를 업데이트합니다.



[그림 3]

[그림 3] 은 **GAN(Generative Adversarial Network)**의 전체 학습 사이클(**GAN Training Cycle**)을 한 장으로 요약한 구조도입니다. **Generator(생성자)**와 **Discriminator(판별자)**가 번갈아 학습하면서 점점 더 사실적인 이미지를 생성하는 과정을 보여줍니다.

전체 학습 흐름



① Random Noise

왼쪽 위의 **Random Noise(z)**는 Generator의 입력입니다.

- 무작위 난수 벡터
- 일반적으로 100 차원 정도의 잠재 벡터(Latent Vector)
- 이미지의 출발점 역할

예를 들어

$z = [0.13, -0.42, 0.81, \dots]$

처럼 구성됩니다.

처음에는 Generator 가 이런 이미지를 만듭니다.

□□□□□□□
□■□■□■□
□□■□■□
■□□□□□

거의 노이즈 수준입니다.

② Generator(G)

Generator 는 랜덤 노이즈를 입력받아 새로운 이미지를 생성합니다.

Noise(z)
▼
Generator
▼
Fake Image G(z)

처음에는 품질이 낮은 이미지를 생성하지만, 반복 학습을 통해 점점 실제 이미지와 유사한 결과를 만들어 냅니다.

③ Fake Data

Generator 가 생성한 가짜 이미지입니다.

Generator
▼
Generated Image

이 이미지는 실제 이미지처럼 보이도록 생성되지만, 아직은 학습 정도에 따라 품질이 달라집니다.

④ Real Data

아래 왼쪽의 **Real Data(x)**는 실제 데이터셋에서 가져온 이미지입니다.

예를 들어

- 사람 얼굴
- 강아지 사진
- 자동차 사진


등 실제 학습용 이미지가 사용됩니다.

⑤ Discriminator(D)

Discriminator 는 두 종류의 이미지를 입력받습니다.

- 실제 이미지(Real Data)
- 생성된 이미지(Fake Data)

그리고 각 이미지가 진짜인지 가짜인지 확률을 출력합니다.



출력 예시는 다음과 같습니다.

0.98 → 진짜일 가능성이 매우 높음
0.03 → 가짜일 가능성이 매우 높음

⑥ Output

Discriminator 의 최종 출력입니다.

Output
↓
Real ?
Fake ?

즉,

"입력된 이미지가 진짜인가, 가짜인가?"

를 판단하는 단계입니다.

⑦ Feedback Loop

그림 상단의 **Feedback Loop** 는 판별 결과를 이용해 Generator 를 개선하는 과정을 의미합니다.

```
Generator
  |
가짜 이미지 생성
  |
Discriminator 평가
  |
오차 계산
  |
Generator 수정
```

판별자의 오차(Gradient)가 역전파되어 Generator 가 더 사실적인 이미지를 생성하도록 가중치가 업데이트됩니다.

STEP 1 : Train Discriminator

첫 번째 단계에서는 **Discriminator 만 학습**합니다.

Generator 는 고정(Fix)한 상태에서,

- 실제 이미지
- 가짜 이미지

를 모두 입력하여

진짜는 진짜
가짜는 가짜

로 정확히 구분하도록 학습합니다.

즉,

Generator : 고정
Discriminator : 학습

입니다.

STEP 2 : Train Generator

두 번째 단계에서는 **Generator 만 학습**합니다.

Discriminator 는 고정한 상태에서,

Generator 가 생성한 이미지를
진짜처럼 보이게
만드는 방향으로 학습합니다.

즉,

Discriminator : 고정
Generator : 학습

입니다.

STEP 3 : Repeat Process

두 신경망을 번갈아 학습하는 과정을 계속 반복합니다.

Discriminator 학습
↓
Generator 학습
↓
Discriminator 학습
↓
Generator 학습
↓
반복

이러한 **교대 학습(Alternating Training)**을 통해 두 모델의 성능이 함께 향상됩니다.

Loss Function

그림 하단에는 두 손실 함수가 표시되어 있습니다.

Discriminator Loss

$$L_D = -E[\log D(x)] - E[\log(1 - D(G(z)))]$$

의미는 다음과 같습니다.

- 실제 이미지는 **진짜(1)**로 맞히도록 학습
- 생성 이미지는 **가짜(0)**로 맞히도록 학습

Generator Loss

$$L_G = -E[\log D(G(z))]$$

Generator 의 목표는

가짜 이미지를 진짜처럼 보이게 만드는 것

입니다.

즉, 판별자가 가짜 이미지를 진짜라고 판단하도록 학습합니다.

2. GAN 학습 알고리즘

1. GAN 학습 알고리즘

for epoch:

- ① 진짜 이미지 선택
- ② 노이즈 생성
- ③ Generator 실행
- ④ 가짜 이미지 생성
- ⑤ Discriminator 학습
- ⑥ Generator 학습

반복

2. Generator 는 어떻게 이미지를 만드는가?

입력

100 차원 노이즈

↓

Fully Connected

↓

Reshape

↓

Transposed Convolution

↓

BatchNorm

↓

ReLU

↓

Transposed Convolution

↓

RGB 이미지

3. Discriminator 는 어떻게 판별하는가?

입력
RGB 이미지
↓
CNN
↓
Feature Extraction
↓
Fully Connected
↓
Sigmoid
↓
진짜 확률

4. 왜 경쟁하면서 학습되는가?

Generator 는

판별자를 속이기 위해

더 좋은 이미지를 만듭니다.

Discriminator 는

속지 않기 위해

더 정확하게 학습합니다.

이를 반복하면

둘 다 계속 발전

하게 됩니다.

5. GAN 학습의 어려움

문제	설명
Mode Collapse	생성자가 일부 패턴만 반복 생성
Gradient Vanishing	판별자가 너무 강해 생성자 학습이 어려움
불안정한 학습	손실 함수가 진동하거나 수렴하지 않음
학습 시간 증가	두 모델을 번갈아 학습해야 함
하이퍼파라미터 민감	학습률, 배치 크기 등에 성능이 크게 좌우됨

6. 대표적인 GAN 모델

모델	특징
GAN	기본 구조
DCGAN	CNN 기반 이미지 생성
Conditional GAN (CGAN)	조건(Label)을 이용한 이미지 생성
Pix2Pix	이미지 변환(Image-to-Image Translation)
CycleGAN	짝이 없는 데이터 간 이미지 변환
SRGAN	초해상도 이미지 생성
StyleGAN	매우 사실적인 얼굴 생성
StyleGAN2	StyleGAN의 품질과 안정성 향상
StyleGAN3	Alias-Free 구조로 자연스러운 이미지 생성
BigGAN	대규모 데이터셋 기반 고품질 이미지 생성

7. GAN의 활용 분야

GAN은 다양한 이미지 생성 및 변환 작업에 활용됩니다.

- 사람 얼굴 생성
- 캐릭터 생성
- 그림 생성
- 사진 복원
- 흑백 이미지 컬러화
- 이미지 초해상도(Super Resolution)

- 스타일 변환
- 의료 영상 생성
- 데이터 증강(Data Augmentation)
- 위성 영상 생성 및 보정





8. GAN 의 장점과 한계

장점

- 매우 사실적인 이미지를 생성할 수 있습니다.
- 별도의 정답 이미지를 직접 생성하도록 학습시키지 않아도 적대적 학습을 통해 품질을 높일 수 있습니다.
- 데이터 증강, 예술 창작, 의료 영상, 게임 그래픽 등 다양한 분야에 활용됩니다.

한계

- 학습이 불안정하여 생성자와 판별자의 균형을 맞추기 어렵습니다.
- Mode Collapse 와 같은 문제가 발생할 수 있습니다.
- 학습 시간이 길고 하이퍼파라미터에 민감합니다.
- 최근에는 이미지 생성 분야에서 **확산 모델(Diffusion Models)**이 품질과 안정성 측면에서 강점을 보여 많은 최신 생성형 AI 서비스의 핵심 기술로 사용되고 있지만, GAN 은 적대적 학습의 원리를 이해하고 고속 이미지 생성이 필요한 응용을 학습하는 데 여전히 중요한 모델입니다.

3. TTS (Text to Speech)

1. TTS(Text-to-Speech)란?

TTS(Text-to-Speech)는 컴퓨터가 텍스트(Text)를 사람의 음성(Speech)으로 변환하여 읽어주는 인공지능 기술이다.

사용자가 입력한 문장이나 LLM이 생성한 답변을 자연스러운 음성으로 변환하여 스피커를 통해 출력한다.

예를 들어,

입력(Text)
안녕하세요. 무엇을 도와드릴까요?
↓
TTS 처리
↓
출력(Speech)
"안녕하세요. 무엇을 도와드릴까요?"

최근의 TTS는 딥러닝 기술의 발전으로 사람의 음성과 매우 유사한 수준의 자연스러운 음성을 생성할 수 있으며, 다양한 언어와 화자의 특성을 반영할 수 있다.

2. TTS의 필요성

TTS 기술은 사람이 직접 문서를 읽지 않아도 컴퓨터가 내용을 음성으로 전달할 수 있도록 해준다. 특히 최근에는 생성형 AI와 결합하여 다양한 음성 서비스를 구현하는 핵심 기술로 활용되고 있다.

대표적인 활용 목적은 다음과 같다.

- 시각장애인을 위한 음성 안내
- AI 챗봇의 음성 답변
- 스마트 스피커
- 차량 내비게이션
- 전자책(E-Book) 읽기
- 온라인 교육 콘텐츠

- 고객센터 자동 응답
- AI 아나운서
- 게임 캐릭터 음성
- 의료 안내 시스템

3. TTS의 활용 분야

분야	활용 예
AI 챗봇	ChatGPT 음성 답변
스마트 스피커	음성 비서
내비게이션	길 안내
교육	영어 발음, 온라인 강의
전자책	책 읽기
고객센터	ARS 자동 응답
방송	AI 아나운서
게임	NPC 음성
의료	병원 안내
접근성	화면 읽기 프로그램

4. TTS의 전체 처리 과정

TTS는 단순히 텍스트를 읽는 것이 아니라 여러 단계를 거쳐 사람의 음성과 유사한 음성을 생성한다.

```

텍스트 입력
↓
Text Normalization
↓
G2P
↓
Acoustic Model
↓
Mel Spectrogram
  
```

↓
Neural Vocoder
↓
Waveform
↓
Speaker

5. 단계별 동작 원리

(1) Text Input

사용자가 입력한 문장 또는 LLM이 생성한 답변을 입력받는다.

예시

오늘 서울의 날씨는 맑습니다.

(2) Text Normalization

숫자, 기호, 약어 등을 사람이 읽기 쉬운 형태로 변환한다.

예시

2026년
↓
이천이십육년

3kg
↓
삼 킬로그램

AI
↓
에이아이

이 과정이 없으면 기계가 숫자나 기호를 부자연스럽게 읽을 수 있다.

(3) Grapheme to Phoneme(G2P)

문자를 실제 발음으로 변환하는 과정이다.

예시

학교

↓

학꾜

같이

↓

가치

한국어에서는 다음과 같은 발음 규칙이 적용된다.

- 연음
- 된소리되기
- 비음화
- 구개음화
- 받침 규칙

G2P는 자연스러운 한국어 음성 생성에 매우 중요한 역할을 한다.

(4) Acoustic Model

발음을 음향 특징(Mel Spectrogram)으로 변환한다.

텍스트

↓

Mel Spectrogram

Mel Spectrogram은 사람이 듣는 주파수 특성을 반영한 시간-주파수 표현으로, 음성의 높이, 길이, 강도 등의 정보를 포함한다.

(5) Neural Vocoder

Mel Spectrogram을 실제 음성 파형(Waveform)으로 변환한다.

Mel Spectrogram



Waveform



Speaker

최종적으로 스피커에서 사람이 말하는 것과 유사한 음성이 출력된다.

6. TTS 시스템 구성

사용자



텍스트 입력



TTS Engine

├─ Text Normalization

├─ G2P

├─ Acoustic Model

├─ Neural Vocoder



Audio



Speaker

7. 주요 구성 요소

구성 요소	역할
Text Normalization	숫자·기호 변환
Tokenizer	문장을 토큰으로 분리
G2P	문자 → 발음 변환
Acoustic Model	발음을 음향 특징으로 변환
Mel Spectrogram	음향 특징 표현
Neural Vocoder	음향 특징을 음성으로 변환


구성 요소	역할
Speaker Encoder	화자 특성 반영
Audio Player	음성 출력

8. 대표적인 TTS 모델

(1) Tacotron

Google에서 제안한 최초의 End-to-End TTS 모델이다.

구조



특징

- Encoder-Decoder 구조
- Attention 사용
- 자연스러운 음성 생성

장점

- 기존 방식보다 음질이 우수하다.
- 구조가 비교적 이해하기 쉽다.

단점

- 추론 속도가 느리다.
- 긴 문장에서 오류가 발생할 수 있다.

(2) Tacotron2

Tacotron을 개선한 모델이다.

추가된 기술

- WaveNet Vocoder
- 음질 향상
- 안정성 향상

Tacotron보다 훨씬 자연스러운 음성을 생성한다.

(3) FastSpeech

Transformer 기반의 TTS 모델이다.

구조

```
graph TD; Text --> Encoder; Encoder --> LengthRegulator[Length Regulator]; LengthRegulator --> Decoder; Decoder --> MelSpectrogram[Mel Spectrogram];
```

Text
↓
Encoder
↓
Length Regulator
↓
Decoder
↓
Mel Spectrogram

특징

- 병렬 처리
- 빠른 추론
- 안정적인 학습

Tacotron보다 훨씬 빠른 음성 생성이 가능하다.

(4) FastSpeech2

FastSpeech의 개선 모델이다.

추가 기능

- Duration Predictor
- Pitch Predictor
- Energy Predictor

이를 통해 더욱 자연스러운 억양과 리듬을 표현할 수 있다.

(5) VITS

(Variational Inference with Adversarial Learning for End-to-End Text-to-Speech)

최근 가장 많이 활용되는 End-to-End TTS 모델 중 하나이다.

특징

- Acoustic Model과 Vocoder를 하나의 모델로 통합
- GAN 기반 학습
- 매우 자연스러운 음성 생성
- 높은 음질
- 높은 학습 효율

(6) XTTS


다국어 및 음성 복제(Voice Cloning)를 지원하는 최신 TTS 모델이다.

특징

- 다국어 지원
- 적은 양의 음성 샘플로 화자 특성 학습
- 실시간 추론 가능
- 음성 스타일 유지

9. 최신 TTS 구조

최근의 대부분 TTS 모델은 Transformer 기반 구조를 사용한다.



Transformer를 활용하면 긴 문장의 문맥을 효과적으로 반영할 수 있으며, 자연스러운 억양과 발음을 생성할 수 있다.

10. Neural Vocoder

Neural Vocoder는 Mel Spectrogram을 실제 음성으로 변환하는 핵심 기술이다.

대표 모델

- WaveNet
- WaveGlow
- HiFi-GAN
- Parallel WaveGAN
- UnivNet
- BigVGAN

처리 과정

Mel Spectrogram

↓

Waveform

최근에는 HiFi-GAN과 BigVGAN이 높은 음질과 빠른 생성 속도로 널리 사용되고 있다.

11. TTS 학습 과정

딥러닝 기반 TTS 모델은 텍스트와 음성 데이터를 함께 학습하여 음성 생성 능력을 획득한다.

텍스트 데이터 + 음성 데이터

↓

전처리

↓

정렬(Alignment)

Acoustic Model 학습

↓

Neural Vocoder 학습

↓

TTS 모델 완성

학습 과정에서는 동일한 문장의 텍스트와 음성 데이터가 쌍(pair)으로 준비되어야 한다.

12. TTS와 STT 비교

항목	TTS	STT
입력	텍스트	음성
출력	음성	텍스트
목적	읽어주기	받아쓰기
대표 기술	Tacotron, FastSpeech, VITS	Whisper, wav2vec 2.0, Conformer
활용	AI 음성 안내	음성 인식

TTS와 STT는 서로 반대 방향의 기술이며, 음성기반 AI 서비스에서는 함께 사용되는 경우가 많다.

13. LLM과 TTS 연계 구조

생성형 AI 서비스에서는 STT, LLM, TTS를 결합하여 자연스러운 음성 대화를 구현한다.

사용자 음성

↓

STT

↓

텍스트

↓

LLM

↓

답변(Text)

↓

TTS

↓

음성 출력

예를 들어, 사용자가 마이크를 통해 질문하면 STT가 음성을 텍스트로 변환하고, LLM이 질문을 이해하여 답변을 생성한 뒤, TTS가 이를 음성으로 변환하여 사용자에게 전달한다.

14. FastAPI 기반 TTS 서비스 구조 예시

FastAPI를 이용하면 음성 입출력을 포함한 AI 서비스를 REST API 형태로 구현할 수 있다.

사용자

↓

FastAPI

↓

STT (Whisper)

↓

LLM (GPT, Qwen 등)

↓

TTS (VITS, XTTS 등)

↓

Audio(.wav)

↓

브라우저 또는 스피커

이 구조는 음성 상담 시스템, RAG 기반 질의응답 서비스, AI 비서, 스마트 스피커 등에서 널리 활용된다.

15. TTS의 장점과 한계

장점

- 사람과 유사한 자연스러운 음성을 생성할 수 있다.
- 시각장애인 등 다양한 사용자의 접근성을 향상시킨다.
- 여러 언어와 화자의 음성을 지원할 수 있다.
- 생성형 AI와 결합하여 음성 기반 서비스를 구현할 수 있다.
- 실시간 음성 합성이 가능하여 다양한 응용 분야에 적용할 수 있다.

한계

- 고품질 모델은 많은 GPU 연산 자원을 요구한다.
- 감정 표현과 억양 제어는 여전히 연구가 진행 중인 분야이다.
- 한국어의 발음 규칙과 고유명사 처리를 위해 추가적인 G2P 최적화가 필요할 수 있다.
- 음성 복제 기술은 개인정보 보호와 악용 방지를 위한 기술적·윤리적 고려가 필요하다.