

교과목 3 : 초거대언어모델(LLM)

단원 6 : 자연어-이미지 멀티모달

DAY3. 멀티모달 AI: Image Captioning과
Stable Diffusion

목 차

1. 이미지 캡셔닝		3
2. Stable Diffusion		10

1. 이미지 캡셔닝(Image Captioning)

1. 이미지 캡셔닝이란?

이미지 캡셔닝(Image Captioning)은 컴퓨터가 이미지를 이해하고 자연어 문장으로 설명하는 인공지능 기술이다.

즉,

- 입력(Input): 이미지
- 출력(Output): 자연어 문장

예를 들어,

입력 이미지	생성된 캡션
강아지가 공원에서 뛰는 사진	"강아지가 공원에서 공을 쫓아 뛰고 있다."
학생이 노트북을 사용하는 사진	"학생이 책상에서 노트북으로 공부하고 있다."
자동차가 도로를 달리는 사진	"빨간 자동차가 도로 위를 주행하고 있다."

단순히 물체를 인식하는(Object Detection) 수준을 넘어 사물의 관계와 상황(Context)까지 이해해야 한다.



Caption: dog is jumping up to catch

2. 이미지 캡셔닝이 필요한 이유

기존 이미지 분류는

이미지
↓
"고양이"

처럼 하나의 클래스만 예측한다.

반면 이미지 캡셔닝은

이미지
↓
"고양이가 창가에서 햇빛을 받으며 잠을 자고 있다."


처럼 **문장 전체**를 생성한다.

즉,

- 무엇이 있는가?
- 어디에 있는가?
- 무엇을 하는가?
- 어떤 관계인가?

까지 설명할 수 있어야 한다.

3. 전체 처리 과정



이미지 입력



이미지 특징 추출 (CNN, ViT)



Feature Vector



Transformer Encoder



Attention



Transformer Decoder



단어 생성



문장 완성

4. 주요 구성 요소

(1) 이미지 특징 추출(Image Encoder)

이미지의 특징을 벡터로 변환한다.

대표 모델

- ResNet
- EfficientNet
- Vision Transformer(ViT)
- CLIP Vision Encoder

예)

이미지



2048 차원 Feature Vector

(2) Encoder

이미지 특징을 의미 있는 표현으로 변환한다.

예)

자동차
↓
차량
↓
도로를 달리는 차량

(3) Attention

문장을 생성하는 동안 이미지의 중요한 부분을 선택한다.

예를 들어

"A boy is riding a bicycle."

생성 시

"A boy"
↓
소년 부분만 집중
"bicycle"
↓
자전거 부분만 집중

(4) Decoder

Transformer Decoder 가

<START>
↓
A
↓
boy
↓


is
↓
riding
↓
a
↓
bicycle
↓
<END>

순서대로 단어를 생성한다.

Encoder-Decoder based Image Captioning Architecture



Reference: <https://arxiv.org/abs/1502.03044>



5. 대표 모델

모델	특징
Show and Tell	CNN + LSTM
Show Attend and Tell	Attention 추가
ViT-GPT2	Vision Transformer + GPT2
BLIP	이미지와 텍스트를 함께 학습
BLIP-2	대규모 LLM 과 연결
Florence	Microsoft 의 멀티모달 모델
GPT-4o Vision	이미지 이해와 설명 지원

6. 학습 데이터

대표 데이터셋

- MS COCO
- Flickr8K
- Flickr30K
- Conceptual Captions
- Visual Genome

예)

Image

↓

5 개의 정답 문장

↓

Loss 계산

↓

모델 학습

7. 손실 함수(Loss)

대부분 Cross Entropy Loss 를 사용한다.

실제 문장

↓

예측 문장

↓

단어별 오차 계산

↓

평균 Loss

8. 성능 평가

대표 평가 지표

- BLEU
- ROUGE
- METEOR
- CIDEr
- SPICE
- BERTScore

최근에는 사람이 평가하는 방식도 함께 사용한다.

9. 활용 분야

- 시각 장애인 음성 안내
- 이미지 검색
- 의료 영상 설명
- 자율주행
- 로봇 비전
- SNS 자동 캡션 생성
- 전자상거래 상품 설명 생성

2. Stable Diffusion

1. Stable Diffusion 이란?

Stable Diffusion 은 텍스트 프롬프트(Text Prompt)를 입력받아 새로운 이미지를 생성하는 생성형 AI 모델이다.

예를 들어,


Prompt

"A cute white cat wearing sunglasses"

↓

이미지 생성

처럼 사람이 문장으로 설명하면 새로운 이미지를 만들어 낸다.



3. Stable Diffusion 의 특징

기존 GAN 은

Generator

↓

이미지 생성 방식이었다.

Stable Diffusion 은

노이즈

↓

점진적 복원(Denoising)

↓

이미지 생성

방식을 사용한다.

3. 전체 구조

Prompt

↓

Tokenizer

↓

Text Encoder (CLIP)

↓

Text Embedding

↓

UNet

↓

Latent Space

↓

VAE Decoder

↓

최종 이미지

4. 주요 구성 요소

(1) Text Encoder

프롬프트를 벡터로 변환한다.

예)

"A red sports car"

↓

768 차원 벡터

(2) Latent Space

픽셀 공간이 아닌 압축된 잠재 공간(Latent Space)에서 이미지를 생성한다.

장점

- 메모리 절약
- 학습 속도 향상
- 생성 속도 향상

(3) UNet

노이즈를 조금씩 제거한다.

Noise

↓

조금 제거

↓

조금 제거

↓

조금 제거

↓

이미지

(4) VAE

Latent 이미지를 실제 이미지로 복원한다.

Latent


↓

Decoder

↓


RGB Image

TEXT-TO-IMAGE GENERATION PIPELINE



5. 생성 과정

- ① Prompt 입력
↓
- ② CLIP Encoding
↓
- ③ Random Noise 생성
↓
- ④ UNet 반복 수행
↓
- ⑤ Noise 제거
↓
- ⑥ Latent 생성
↓
- ⑦ VAE Decoder
↓
- ⑧ 최종 이미지 출력



6. 왜 Diffusion 이라 하는가?

학습 과정에서는

원본 이미지

↓

노이즈 추가

↓

거의 랜덤 노이즈

로 데이터를 변형하는 **Forward Diffusion** 을 학습한다.

생성 과정에서는

랜덤 노이즈


↓

노이즈 제거

↓

이미지 생성

인 **Reverse Diffusion** 을 수행한다.



7. Stable Diffusion 의 장점

- 고품질 이미지 생성
- 다양한 스타일 표현
- 텍스트 기반 생성(Text-to-Image)
- 이미지 편집(Image-to-Image)
- 인페인팅(Inpainting)
- 아웃페인팅(Outpainting)
- 로컬 환경에서도 실행 가능
- 다양한 오픈소스 모델과 확장성

8. 대표 활용 분야

- AI 일러스트 제작
- 광고 디자인
- 게임 캐릭터 생성
- 영화 콘셉트 아트
- 건축 시각화
- 패션 디자인
- 제품 디자인
- 교육용 이미지 제작

이미지 캡셔닝과 Stable Diffusion 비교

구분	이미지 캡셔닝	Stable Diffusion
입력	이미지	텍스트 프롬프트
출력	자연어 문장	새로운 이미지
목적	이미지 이해	이미지 생성
핵심 기술	Vision Encoder + Transformer Decoder	CLIP + UNet + VAE + Diffusion
대표 모델	BLIP, BLIP-2, ViT-GPT2	Stable Diffusion 1.x, 2.x, SDXL
활용	이미지 설명, 검색, 접근성	생성형 AI, 디자인, 콘텐츠 제작

핵심 정리

- 이미지 캡셔닝(Image Captioning)은 이미지를 입력받아 의미를 이해하고 자연어 문장을 생성하는 기술로, 컴퓨터 비전과 자연어 처리(NLP)를 결합한 대표적인 멀티모달 AI 기술이다.
- Stable Diffusion 은 텍스트 프롬프트를 입력받아 잠재 공간(Latent Space)에서 노이즈를 반복적으로 제거하며 새로운 이미지를 생성하는 확산(Diffusion) 기반 생성형 AI 모델이다.
- 이미지 캡셔닝은 "이미지 → 텍스트" 변환을 수행하는 반면, Stable Diffusion 은 "텍스트 → 이미지" 생성을 수행한다.
- 최근 멀티모달 AI 시스템에서는 두 기술을 함께 활용하여 이미지 이해(캡셔닝)와 이미지 생성(Stable Diffusion)을 하나의 서비스에서 통합하는 사례가 늘어나고 있다.