

교과목 2 : 데이터 분석과 머신러닝 / 딥러닝

단원 4 : 모델 검증 및 평가

DAY1. AI 모델 검증 및 평가

목 차

1. AI 모델 검증 및 평가		3
2. 분류 모델 평가		6
3. 회귀 모델 평가		12
4. 딥러닝에서의 검증		16

1. AI 모델 검증(Validation) 및 평가(Evaluation)

AI 모델을 만드는 목적은 학습에 사용한 데이터를 외우는 것이 아니라, 새로운 데이터를 만나도 정확하게 예측하는 것이다. 따라서 모델을 학습한 후에는 반드시 모델의 성능을 검증하고 평가해야 한다.

1. 모델 검증(Validation)과 평가(Evaluation)의 차이

많은 사람들이 검증과 평가를 같은 의미로 사용하지만 실제로는 목적이 다르다.

구분	목적	사용 데이터
학습(Training)	모델이 패턴 학습	학습 데이터
검증(Validation)	모델 튜닝	검증 데이터
평가(Test)	최종 성능 확인	테스트 데이터


예를 들어 학생이 시험을 준비한다고 가정해 보자.

- 학습 데이터 → 교과서
- 검증 데이터 → 모의고사
- 테스트 데이터 → 실제 수능

모의고사 결과를 보고 공부 방법을 바꿀 수 있지만 실제 수능 문제는 미리 보면 안 된다. AI 도 동일하다.

2. 데이터 분할(Data Split)

일반적으로 데이터를 다음과 같이 나눈다.



예시

데이터가 10,000 개인 경우

학습 데이터 : 7,000개
검증 데이터 : 1,500개
테스트 데이터 : 1,500개

3. 왜 검증이 필요한가?

모델은 학습할수록 훈련 데이터에 점점 맞춰진다.

하지만 너무 많이 학습하면 새로운 데이터에서는 성능이 떨어질 수 있다.

이를 **과적합(Overfitting)** 이라고 한다.

예시

학생이 기출문제를 외운 경우

기출문제 점수 : 100점
새 문제 점수 : 60점

AI 모델도 마찬가지이다.

훈련 정확도 : 99%
테스트 정확도 : 65%

이 경우 과적합이 발생한 것이다.

4. 모델 평가 과정

전체 과정은 다음과 같다.

데이터 수집



전처리



학습 데이터로 모델 학습



검증 데이터로 튜닝



최종 모델 선정



테스트 데이터로 최종 평가

2. 분류(Classification) 모델 평가

분류는 정답 클래스를 맞추는 문제이다.

예시

고양이
강아지
토끼

정확도(Accuracy)

가장 많이 사용하는 평가 지표이다.

공식

$$Accuracy = \frac{\text{정확하게 예측한 개수}}{\text{전체 데이터 개수}}$$

예시

100 개 중

90개 맞출
10개 틀림

이면

$$\begin{aligned} Accuracy &= \frac{90}{100} \\ &= 0.9 \\ &= 90\% \end{aligned}$$

정확도의 한계

암 진단 데이터를 생각해 보자.

정상 환자 : 990명

암 환자 : 10명

모두 정상이라고 예측하면

990개 맞음

10개 틀림

정확도

$$\begin{aligned} \text{Accuracy} &= \frac{990}{1000} \\ &= 99\% \end{aligned}$$

99%인데 좋은 모델일까?

아니다.

암 환자를 하나도 찾지 못했기 때문이다.

그래서 다른 지표도 필요하다.

6. 혼동행렬(Confusion Matrix)

분류 문제의 가장 기본적인 평가 방법이다.

실제/예측	양성	음성
양성	TP	FN
음성	FP	TN

TP(True Positive)

실제 양성을 양성으로 맞춤

예시

실제 암 환자
예측 암 환자

TN(True Negative)

실제 음성을 음성으로 맞춤

예시

실제 정상
예측 정상

FP(False Positive)

실제 정상인데 양성으로 예측

예시

실제 정상
예측 암

FN(False Negative)

실제 암인데 정상으로 예측

예시

실제 암
예측 정상

가장 위험한 오류이다.

2. 정밀도(Precision)

양성이라고 예측한 것 중 실제 양성 비율

공식

$$Precision = \frac{TP}{TP + FP}$$

예시

양성 예측 : 100명
실제 양성 : 80명

Precision=

$$\begin{aligned} Precision &= \frac{80}{100} \\ &= 0.8 \\ &= 80\% \end{aligned}$$

의미

모델이 양성이라고 말한 것 중 80%가 진짜 양성

3. 재현율(Recall)

실제 양성 중 찾아낸 비율

공식

$$Recall = \frac{TP}{TP + FN}$$

예시

실제 암 환자 : 100명
찾은 암 환자 : 90명

Recall=

$$\begin{aligned} Recall &= \frac{90}{100} \\ &= 90\% \end{aligned}$$

의미

실제 존재하는 양성을 얼마나 잘 찾았는가를 나타낸다.

4. F1 Score

정밀도와 재현율을 동시에 고려한다.

공식

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

예시

```
Precision = 0.8  
Recall = 0.9
```

$$\begin{aligned} F1 &= 2 \times \frac{0.8 \times 0.9}{0.8 + 0.9} \\ &= \frac{1.44}{1.7} \\ &= 0.847 \\ &= 84.7\% \end{aligned}$$

5. ROC Curve

분류 임계값(Threshold)을 변화시키면서 성능을 확인하는 그래프이다.

축

X축 : FPR

Y축 : TPR

TPR(True Positive Rate)

재현율과 동일

$$TPR = \frac{TP}{TP + FN}$$

FPR(False Positive Rate)

$$FPR = \frac{FP}{FP + TN}$$

좋은 모델은 왼쪽 위에 가까움

6. AUC

ROC Curve 아래 면적

범위

0.5 : 랜덤

0.7 : 보통

0.8 : 좋음

0.9 이상 : 매우 좋음

1.0 : 완벽

3. 회귀(Regression) 평가

회귀는 숫자를 예측하는 문제이다.

예시

집값 예측
매출 예측
주가 예측

1. MAE (Mean Absolute Error)

평균 절대 오차

공식

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

기호 의미

- y : 실제값
- $\hat{y}$: 예측값

예시

실제값	예측값
10	12
20	18
30	35

오차

2
2
5

MAE

$$\frac{2 + 2 + 5}{3} = 3$$

2. MSE (Mean Squared Error)

오차 제곱 평균

공식

$$MSE = \frac{1}{n} \sum (y_i - \hat{y}_i)^2$$

예시

오차

2
2
5

제공

4
4
25

MSE

$$\frac{4 + 4 + 25}{3} = 11$$

특징

큰 오차를 더 크게 벌점 준다.

3. RMSE

MSE 의 제곱근

공식

$$RMSE = \sqrt{MSE}$$

예시

$$\begin{aligned} RMSE &= \sqrt{11} \\ &= 3.317 \end{aligned}$$

실제 데이터 단위와 동일하여 해석이 쉽다.

4. 결정계수(R²)

모델 설명력을 나타낸다.

공식

$$R^2 = 1 - \frac{\sum (y - \hat{y})^2}{\sum (y - \bar{y})^2}$$

의미

모델이 데이터를 얼마나 설명하는지 나타낸다.

값 해석

R ² 값	의미
1.0	완벽 예측
0.9 이상	매우 우수
0.8 이상	우수
0.7 이상	양호
0	평균 수준
음수	평균보다 못함

5. 교차 검증(Cross Validation)

데이터가 적을 때 많이 사용한다.

대표적으로 K-Fold 검증을 사용한다.

예시

$K = 5$

데이터를 5 개로 나눈다.

1회차

학습 : 2 3 4 5

검증 : 1

2회차

학습 : 1 3 4 5

검증 : 2

...

5회차

학습 : 1 2 3 4

검증 : 5

최종 성능

$$\text{평균정확도} = \frac{Fold1 + Fold2 + Fold3 + Fold4 + Fold5}{5}$$

4. 딥러닝에서의 검증

딥러닝은 매 Epoch 마다 검증 데이터를 사용한다.

예시

```
Epoch 1  
Train Loss = 0.80  
Val Loss = 0.90  
  
Epoch 20  
Train Loss = 0.10  
Val Loss = 0.15  
  
Epoch 50  
Train Loss = 0.01  
Val Loss = 0.70
```

Epoch 50 에서 과적합이 발생하였다.

1. Early Stopping

검증 성능이 더 이상 좋아지지 않으면 학습을 중단한다.

예시

```
EarlyStopping(  
    monitor='val_loss',  
    patience=5  
)
```

의미

5 번 동안 개선이 없으면 학습 종료

2. AI 모델 평가의 핵심

좋은 AI 모델은 단순히 학습 데이터에서 높은 정확도를 보이는 모델이 아니다.

다음 조건을 모두 만족해야 한다.

1. 학습 데이터에서 충분히 학습한다.
2. 검증 데이터에서 안정적인 성능을 보인다.
3. 테스트 데이터에서도 비슷한 성능을 유지한다.
4. 과적합이 발생하지 않는다.
5. 문제 유형에 맞는 평가 지표를 사용한다.

즉, 모델 검증과 평가는 "모델이 실제 환경에서도 잘 동작하는지 확인하는 과정"이며, AI 프로젝트에서 모델 설계만큼 중요한 단계이다.